Super-Convergence

Идея статьи и воспроизведение результатов

MNIST / LeNet

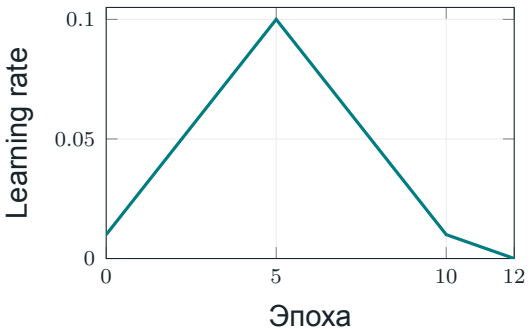
CIFAR-10 / ResNet-56

Leslie N. Smith, Nicholay Topin

arXiv:1708.07120v3, 2018

Эффективные нейронные сети

Идея статьи и расписание 1cycle



LR растёт до большого значения, затем снижается. В конце он становится очень малым.

Авторы связывают эффект с регуляризацией большим LR. Её нужно согласовать с weight decay.

LR range test помогает выбрать диапазон. В нашей работе диапазон задан заранее.

Smith & Topin, раздел 3. На графике показано расписание нашего MNIST-эксперимента.

Что воспроизводили

Модель и данные	Baseline	1cycle	Seed
MNIST / LeNet	85 эпох	12 эпох	0, 1, 2
CIFAR-10 / ResNet-56	200 эпох	25 эпох	0

Полные датасеты, batch 512, PyTorch, Colab с Tesla T4.

Сравниваем последние эпохи и baseline на коротком бюджете.

CIFAR имеет адаптированные настройки:

меньше шагов, максимум LR 1 вместо 3, изменённые детали архитектуры и BatchNorm.

MNIST: ориентир из таблицы 2 статьи. Настройки CIFAR сохранены в config.json.

Результаты MNIST

Режим	Эпохи	Наша accuracy, %	Статья, %
Baseline короткий	12	$98{,}703 \pm 0{,}075$	—
Baseline полный	85	$99{,}020 \pm 0{,}061$	$99{,}03 \pm 0{,}04$
1cycle	12	$99{,}127 \pm 0{,}051$	$99{,}25 \pm 0{,}03$

1cycle лучше длинного baseline на 0,107 п.п.

Число эпох меньше в 7,1 раза. Результат 1cycle ниже опубликованного на 0,123 п.п.

Среднее $\pm$ выборочное SD по трём seed. Статья: таблица 2. Наши числа перенесены из проверенной сводки Colab; первичный архив MNIST не приложен.

Результаты CIFAR-10

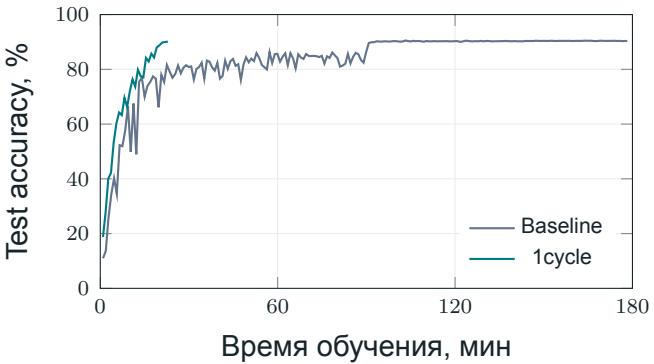
Режим	Эпохи	Accuracy, %	Обучение, мин
Baseline короткий	25	79,16	23,47
Baseline полный	200	90,34	178,26
1cycle	25	90,12	22,86

Разница с длинным baseline составляет $-0{,}22$ п.п.

Полный запуск 1cycle короче по времени в 7,8 раза. При одинаковых 25 эпохах преимущество равно 10,96 п.п.

Один seed. Время обучения исключает оценку test, сохранение checkpoints и перерывы. Источник: summary.csv.

CIFAR: скорость достижения качества



Порог accuracy: 90,12%.

93,46 мин

Baseline, эпоха 104.

22,86 мин

1cycle, эпоха 25.

Разница около 4,1 раза.

Порог выбран после эксперимента. Это описательное сравнение траекторий. Источник: history.csv.

Выводы и ограничения

Короткий 1cycle дал близкую или более высокую точность в выполненных экспериментах.

- MNIST: частичное численное воспроизведение, три seed.
- CIFAR: проверка идеи с изменёнными настройками, один seed. Разброс неизвестен.
- LR range test, анализ гессиана и эксперименты ImageNet не воспроизводились.

Статья: arxiv.org/abs/1708.07120. Подробности и различия протоколов приведены в отчёте.