Воспроизведение Super-Convergence

Эффективные нейронные сети

10 октября 2026 года

Работа проверяет, позволяет ли расписание 1cycle сократить обучение при близкой итоговой точности. На MNIST короткий запуск превзошёл длинный baseline. В дополнительном эксперименте CIFAR-10 он уступил на 0,22 процентного пункта при сокращении времени полного бюджета в 7,8 раза. Численные результаты статьи воспроизведены частично.

Идея статьи

Leslie N. Smith и Nicholay Topin исследуют super-convergence: обучение с одним циклом learning rate и большим максимальным LR [1]. Сначала LR растёт, затем снижается, а в конце становится очень малым. Авторы связывают эффект с регуляризацией большим LR и необходимостью согласовать её с weight decay и другими источниками регуляризации. LR range test помогает выбрать диапазон. В этой работе диапазоны заданы заранее, LR range test и анализ гессиана не воспроизводятся.

Постановка экспериментов

Реализация написана на PyTorch, исходная статья использует Caffe. Все запуски выполнены на Tesla T4 в Colab, в float32. Test используется для регистрации метрик после эпохи, без выбора лучшего checkpoint. В таблицах показана последняя эпоха. Время обучения включает вычисления и передачу batches, но исключает test, сохранение файлов, загрузку датасета и перерывы сессий.

MNIST и LeNet

Полные 60 000 train и 10 000 test изображений, batch 512, без аугментаций, пиксели делятся на 256. LeNet содержит 431 080 параметров. Для baseline используется inverse decay:

$$\eta_t = 0{,}01\,(1 + 0{,}0001t)^{-0{,}75},$$

где t обозначает шаг оптимизатора. Momentum равен 0,9.

В 1cycle LR меняется от 0,01 до 0,1 и обратно за 10 эпох, затем снижается до 0,00001 за две эпохи. Momentum меняется от 0,95 до 0,8 и обратно. Weight decay равен 0,0005. Выполнены seed 0, 1, 2.

Режим	Эпохи	Accuracy, %	Статья, %
Baseline короткий	12	$98{,}703 \pm 0{,}075$	нет сравнения
Baseline полный	85	$99{,}020 \pm 0{,}061$	$99{,}03 \pm 0{,}04$
1cycle	12	$99{,}127 \pm 0{,}051$	$99{,}25 \pm 0{,}03$

Таблица 1: Результаты MNIST. Среднее и выборочное SD по трём seed.

Указано среднее ± выборочное SD. Преимущество 1cycle над длинным baseline составляет 0,107 п.п. при 7,1-кратном сокращении числа эпох. Отставание 1cycle от опубликованного значения составляет 0,123 п.п. Источник измерений MNIST: ранее проверенная сводная таблица Colab. Первичный архив MNIST в комплект не предоставлен, сводка сохранена с этой пометкой.

CIFAR-10 и ResNet-56

Полные 50 000 train и 10 000 test изображений, batch 512. Train: random crop 32×32 с padding 4, horizontal flip и нормализация каналов. Test без случайных преобразований. ResNet-56 имеет стадии с каналами 16, 32 и 64. PyTorch SGD: momentum 0,9, weight decay 0,0001 только для матриц весов. BatchNorm momentum 0,05 одинаков в обоих режимах.

В протоколе colab baseline обучается 200 эпох с LR 0,1 и снижениями в 10 раз после 100 и 150 эпох. 1cycle обучается 25 эпох: по 11 эпох на рост LR от 0,1 до 1 и возврат, затем 3 эпохи до 0,00001. Выполнен один seed 0. Это дополнительный эксперимент с изменённым бюджетом, а не точное повторение CIFAR-результатов статьи.

Режим	Эпохи	Accuracy, %	Test loss	Время, мин
Baseline короткий	25	79,16	0,645	23,47
Baseline полный	200	90,34	0,565	178,26
1cycle	25	90,12	0,311	22,86

Таблица 2: Результаты CIFAR-10 для seed 0. Время обучения без оценки test.

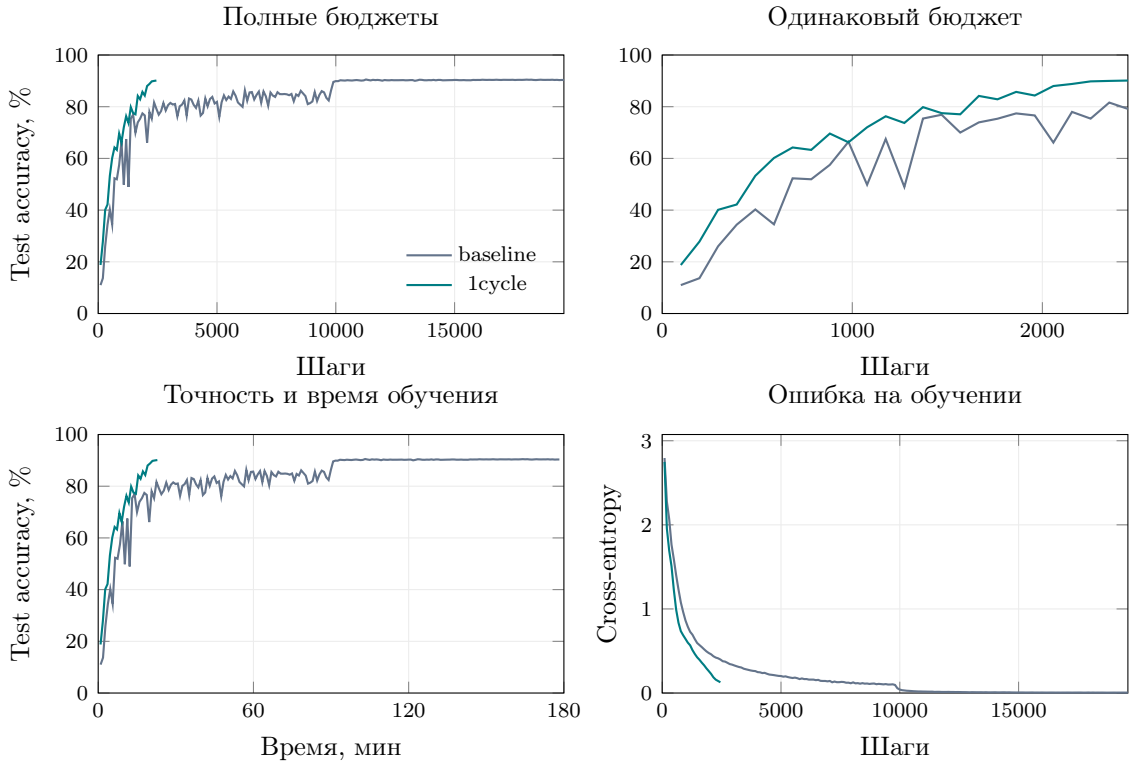


Рис. 1: Кривые CIFAR-10 для одного seed. Полоса SD отсутствует, так как повтор один. Число шагов на эпоху равно 98. Источник: `results/cifar10/history.csv`.

Интерпретация результатов

На CIFAR-10 1cycle дал близкую accuracy за 25 эпох: 90,12% против 90,34% за 200 эпох. Разница составляет −0,22 п.п. При одинаковых 25 эпохах преимущество равно 10,96 п.п. Отношение времени полных запусков составляет 7,80, отношение числа шагов равно 8.

Ускорение до одинакового уровня качества меньше. Baseline впервые достиг accuracy не ниже итоговых 90,12% метода 1cycle на 104-й эпохе: 90,23% за 93,46 минуты. Сравнение с 22,86 минуты для 1cycle даёт около 4,09 раза. Порог выбран после просмотра результатов, это описательное сравнение траекторий, а не заранее заданный критерий остановки.

После первого снижения LR baseline вырос с 86,30% на 100-й эпохе до 89,59% на 101-й. Его train loss продолжал уменьшаться, а accuracy затем менялась мало. У 1cycle ниже итоговый test loss: 0,311 против 0,565. Это совместимо с меньшим переобучением, но не доказывает механизм регуляризации или лучшую калибровку вероятностей.

Ограничения воспроизведения

MNIST использует SGD с формулой momentum buffer из Caffe, но отличается окружением, shuffle, неполным последним batch и выбранным конечным LR. Поэтому близость к таблице 2 не означает побитное воспроизведение. CIFAR использует стандартный PyTorch SGD, другой бюджет, диапазон LR и настройки BatchNorm. Shortcut option A и входной stride 1 отличаются от описания архитектуры в приложении статьи. Прямое численное сравнение CIFAR с исходной таблицей некорректно.

Один seed CIFAR не позволяет оценить разброс или заявлять статистическую эквивалентность. Три seed MNIST также дают ограниченную оценку устойчивости. Вычисления подтверждают эффект для выбранных расписаний, но не доказывают преимущество над любым настроенным baseline. ImageNet, CIFAR-100 и остальные архитектуры не воспроизводились.

Список литературы

[1] Smith L. N., Topin N. Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates. arXiv:1708.07120v3, 2018. https://arxiv.org/abs/1708.07120.

[2] Собственные результаты CIFAR-10: архив `full_results-2.zip`, файлы `config.json`, `history.csv`, `summary.csv` и `paired_comparisons.csv`.

[3] Сводная таблица выполненного MNIST-ноутбука Colab, проверенная в ходе работы.